

1.

תהי  $A$  מטריצה סימטרית שהיא PSD. מכיוון ש- $A$  סימטרית מתקיים כי קיימת מטריצה  $Q$  אורתוגונלית כך ש  $A = QDQ^T$  כאשר  $D$  אלכסונית (ובאלכסון נמצאים הערכים העצמיים של  $A$ ). מתקיים כי הע"ע של  $A$  אי-שליליים: יהי  $\lambda$  ע"ע של  $A$  ו- $v$  ו"ע מתאים, מתקיים כי  $\lambda \geq 0 \Rightarrow v^T Av = v^T \lambda v = \lambda \|v\|_2^2 \geq 0$  לכן נוכל להגדיר מטריצה חדשה  $D'$  באופן הבא:  $D'_{ij} = \sqrt{D_{ij}}$ . מכיוון ש  $D$  אלכסונית, מתקיים כי  $D'D' = D$ .

לכן

$$A = QDQ^T = QD'D'Q^T = (D'^T Q^T)^T D'Q^T = (D'Q^T)^T D'Q^T$$

וזו מה שרצינו להוכיח.

תהי  $A$  מטריצה כך שניתנת לפירוק באופן הבא:  $A = XX^T$ . נראה כי היא סימטרית:

$$A^T = (XX^T)^T = XX^T = A$$

כעת נראה כי היא PSD:

יהי  $v \in \mathbb{R}^n$  כלשהו. מתקיים כי

$$v^T Av = v^T XX^T v = (X^T v)^T X^T v = \sum_{i=1}^n X^T v_i^2 \geq 0$$

לכן  $A$  היא מטריצה סימטרית ו-PSD.

2. יהיו  $\alpha, \beta \geq 0$  ממשיים ו- $A, B \in \mathbb{R}^{n \times n}$  מטריצות PSD. נראה כי  $\alpha A + \beta B$  היא PSD. ראשית, נראה כי היא סימטרית:

$$(\alpha A + \beta B)^T = \alpha A^T + \beta B^T = \alpha A + \beta B$$

כעת נבדוק כי היא PSD:

יהי  $v \in \mathbb{R}^n$  כלשהו. מתקיים כי

$$v^T (\alpha A + \beta B) v = v^T (\alpha Av + \beta Bv) = \alpha v^T Av + \beta v^T Bv$$

ומכיוון ש- $v^T Av \geq 0, v^T Bv \geq 0, \alpha, \beta \geq 0$ , נקבל כי  $v^T (\alpha A + \beta B) v = \alpha v^T Av + \beta v^T Bv \geq 0$

לכן  $\alpha A + \beta B$  היא PSD.

לא מתקיים כי  $M_{psd} \stackrel{\text{def}}{=} \{A \in \mathbb{R}^{n \times n} \mid A \text{ is PSD}\}$  הוא מרחב וקטורי מעל  $\mathbb{R}$ . נתבונן במטריצת היחידה  $I_n$ . מתקיים כי היא ניתנת לפירוק ע"י  $I_n = I_n I_n^T$ , לכן לפי הסעיף הראשון היא סימטרית והיא PSD, כלומר  $I_n \in M_{psd}$ . לו  $M_{psd}$  היה מרחב וקטורי מעל  $\mathbb{R}$  היה מתקיים כי  $-I_n \in M_{psd}$ , אבל לכל  $v \in \mathbb{R}^n$  מתקיים כי  $v^T (-I_n) v = -v^T v \leq 0$  ולכן  $I_n$  לא PSD.

1. בהינתן משתנים מקריים ב"ת המתפלגים  $U[0,1]$  נמצא צפיפות, ונחשב את התוחלת והשונות של  $Y = \max(X_1, \dots, X_n)$ .

$$\begin{aligned} F_Y(t) &= \mathbb{P}[Y \leq t] = \mathbb{P}[\max(X_1, \dots, X_n) \leq t] = \mathbb{P}[X_1 \leq t, \dots, X_n \leq t] \\ &= \prod_{i=1}^n \mathbb{P}[X_i \leq t] = \mathbb{P}[U[0,1] \leq t]^n = \left( \int_{-\infty}^t 1_{[0,1]} ds \right)^n \\ &= \begin{cases} 0 & \text{if } t < 0, \\ t^n & \text{if } t \in [0,1], \\ 1 & \text{if } t > 1 \end{cases} \end{aligned}$$

כאשר המעברים מוצדקים כי  $X_1, \dots, X_n$  ב"ת ומתפלגים  $U[0,1]$ .  
אם נגדיר  $f_Y(t) = nt^{n-1}1_{[0,1]}$  נקבל כי  $F_Y(t) = \int_{-\infty}^t f_Y(s) ds$ . כלומר מצאנו צפיפות עבור  $Y$ .


כעת נחשב את התוחלת והשונות:

$$\mathbb{E}[Y] = \int_{-\infty}^{\infty} t f_Y(t) dt = \int_0^1 t n t^{n-1} ds = \int_0^1 n t^n dt = \left[ \frac{n}{n+1} t^{n+1} \right]_0^1 = 1 - \frac{1}{n+1}$$


$$E[Y^2] = \int_{-\infty}^{\infty} t^2 f_Y(t) dt = \int_0^1 n t^{n+1} dt = \left[ \frac{n}{n+2} t^{n+2} \right]_0^1 = 1 - \frac{2}{n+2}$$

$$\begin{aligned} \text{Var}[Y] &= E[Y^2] - E[Y]^2 = 1 - \frac{2}{n+2} - \left( 1 - \frac{1}{n+1} \right)^2 \\ &= 1 - \frac{2}{n+2} - \left( 1 - \frac{2}{n+1} + \frac{1}{(n+1)^2} \right) = \frac{2}{n+1} - \frac{2}{n+2} - \frac{1}{(n+1)^2} \\ &= \frac{2(n+1)(n+2) - 2(n+1)^2 - n - 2}{(n+2)(n+1)^2} \\ &= \frac{2(n+1)(n+2 - n - 1) - n - 2}{(n+2)(n+1)^2} = \frac{2n+2 - n - 2}{(n+2)(n+1)^2} = \frac{n}{(n+2)(n+1)^2} \end{aligned}$$

אפשר לראות כי ככל ש- $n$  גדל, ה- $PDF$  נהיה פולינום מדרגה גבוהה יותר.  
שרטטתי גרף עבור  $n$  בין 1 ל-10, ואכן ניתן לראות זאת:



לגבי התוחלת ניתן לראות כי ככל ש- $n$  גדל, כך היא שואפת ל-1, והשונות שואפת ל-0. שרטטתי את התוחלת והשונות כפונקציה של  $n$ .



2.

יהי  $X$  משתנה מקרי רציף, כלומר  $F_X$  רציפה. מכיוון ש- $\lim_{t \rightarrow -\infty} F_X(t) = 0$  ו- $\lim_{t \rightarrow \infty} F_X(t) = 1$  נובע ממשפט ערך הביניים כי קיים  $m \in \mathbb{R}$  כך שמתקיים כי  $\mathbb{P}[X \leq m] = F_X(m) = \frac{1}{2}$ .

בהנחה כי קיים  $m$  יחיד כזה, נוכיח כי  $m = \operatorname{argmin}_{a \in \mathbb{R}} \mathbb{E}[|X - a|]$ .

יהי  $a \in \mathbb{R}$ .

נגדיר  $Y = X - a$ . מתקיים כי  $Y$  מ"מ (כי הרכבה של פונקציות מדידות היא מדידה). נחשב:  
 $F_Y(t) = \mathbb{P}[Y \leq t] = \mathbb{P}[X - a \leq t] = \mathbb{P}[X \leq a + t] = F_X(a + t)$   
 וזו רציפה כהרכבה של פונקציות רציפות. לכן  $Y$  מ"מ רציף.

נחשב את התוחלת של  $|Y|$ :

$$\begin{aligned} \mathbb{E}[|Y|] &= \mathbb{E}[Y^+ + Y^-] = \mathbb{E}[Y^+] + \mathbb{E}[Y^-] = \int_0^\infty (1 - F_Y(t)) dt + \int_0^\infty F_Y(-t) dt \\ &= \int_0^\infty (1 - F_Y(t)) dt + \int_{-\infty}^0 F_Y(t) dt \\ &= \int_0^\infty (1 - F_X(t + a)) dt + \int_{-\infty}^0 F_X(t + a) dt \end{aligned}$$

ע"י החלפת משתנים  $u = t + a$  נקבל

$$M(a) \stackrel{\text{def}}{=} \mathbb{E}[|X - a|] = \mathbb{E}[|Y|] = \int_a^\infty (1 - F_X(u)) du + \int_{-\infty}^a F_X(u) du$$

מכיוון ש- $F_X$  רציפה נקבל מהמשפט היסודי של החשבון האינפיניטסימלי כי

$$M'(a) = -(1 - F_X(a)) + F_X(a) = 2F_X(a) - 1$$

אם נשווה את הנגזרת ל-0 נקבל כי קיימת נקודה קריטית כאשר  $\frac{1}{2}$ .  $\mathbb{P}[X \leq a] = F_X(a) = \frac{1}{2}$ .

מתקיים כי זוהי נקודת מינימום כי:

- עבור  $t \leq a$  מתקיים כי  $M'(t) \leq 0$

- עבור  $t \geq a$  מתקיים כי  $M'(t) \geq 0$

(משום ש- $F_X$  מונוטונית לא יורדת כפונקציית התפלגות צוברת).

לכן מתקיים כי החציון מתקבל ב

$$m = \operatorname{argmin}_{a \in \mathbb{R}} \mathbb{E}[|Y|] = \operatorname{argmin}_{a \in \mathbb{R}} \mathbb{E}[|X - a|]$$

.1

.a

תהי  $f: \mathcal{X} \rightarrow \mathcal{Y}$  היפותזה כלשהי.

נחשב את תוחלת השגיאה עבור  $\ell_{0-1}$ :

$$\mathbb{E}[\ell_{0-1}(Y, f(X))] = \sum_{(x,y) \in (\mathcal{X} \times \mathcal{Y})} \mathbb{P}[X = x, Y = y] \ell_{0-1}(y, f(x))$$

יהי  $x \in \mathcal{X}$ , מתקיים כי הגורמים היחידים שהוא מופיע בהם הם:  
 $\{\mathbb{P}[X = x, Y = y] \ell_{0-1}(y, f(x))\}_{y \in \mathcal{Y}}$

נתבונן בשגיאה הנצברת שלהם:

$$\begin{aligned} \sum_{y \in \mathcal{Y}} \mathbb{P}[X = x, Y = y] \ell_{0-1}(y, f(x)) &= \sum_{i=1}^L \mathbb{P}[X = x, Y = i] \ell_{0-1}(i, f(x)) \\ &= \mathbb{P}[X = x] \sum_{i=1}^L \mathbb{P}[Y = i | X = x] \ell_{0-1}(i, f(x)) \end{aligned}$$

אנו רוצים למזער את תוחלת השגיאה ככל הניתן ע"י קביעת  $h(x)$ .

נשים לב כי אם  $h(x) = j, 1 \leq j \leq L$ :

$$\begin{aligned} &\mathbb{P}[X = x] \sum_{i=1}^L \mathbb{P}[Y = i | X = x] \ell_{0-1}(i, f(x)) \\ &= \mathbb{P}[X = x] \sum_{i=1}^L \mathbb{P}[Y = i | X = x] \ell_{0-1}(i, j) \\ &= \mathbb{P}[X = x] \sum_{i \in \mathcal{Y} / \{j\}} \mathbb{P}[Y = i | X = x] \end{aligned}$$

לכן אם נבחר כי  $h(x) \in \operatorname{argmax}_{i \in \mathcal{Y}} \mathbb{P}[Y = i | X = x]$  נקבל כי הביטוי שלמעלה  
 מזערי:

יהי  $i \in \mathcal{Y} / \{j\}, j \in \operatorname{argmax}_{i \in \mathcal{Y}} \mathbb{P}[Y = i | X = x]$  מתקיים כי  
 $\mathbb{P}[Y = i | X = x] \leq \mathbb{P}[Y = j | X = x]$

לכן

$$\begin{aligned}
 & \mathbb{P}[X = x] \sum_{i \in \mathcal{Y} / \{i\}} \mathbb{P}[Y = i | X = x] \\
 &= \mathbb{P}[X = x] \left( \sum_{i \in \mathcal{Y} / \{i, j\}} \mathbb{P}[Y = i | X = x] + \mathbb{P}[Y = j | X = x] \right) \\
 &\geq \mathbb{P}[X = x] \left( \sum_{i \in \mathcal{Y} / \{i, j\}} \mathbb{P}[Y = i | X = x] + \mathbb{P}[Y = i | X = x] \right) \\
 &= \mathbb{P}[X = x] \sum_{i \in \mathcal{Y} / \{j\}} \mathbb{P}[Y = i | X = x]
 \end{aligned}$$

כלומר הראנו כי עבור  $x \in \mathcal{X}$  קביעת  $h(x) \in \operatorname{argmax}_{i \in \mathcal{Y}} \mathbb{P}[Y = i | X = x]$  ממזערת את תוחלת השגיאה.

.b

תהי  $f: \mathcal{X} \rightarrow \mathcal{Y}$  היפותזה כלשהי.

נחשב את תוחלת השגיאה עבור  $\Delta$ :

$$\mathbb{E}[\ell_{0-1}(Y, f(X))] = \sum_{(x, y) \in (\mathcal{X} \times \mathcal{Y})} \mathbb{P}[X = x, Y = y] \Delta(y, f(x))$$

יהי  $x \in \mathcal{X}$ , מתקיים כי הגורמים היחידים שהוא מופיע בהם הם:

$$\{\mathbb{P}[X = x, Y = y] \Delta(y, f(x))\}_{y \in \{0, 1\}}$$

נתבונן בסכומם:

$$\begin{aligned}
 & \sum_{y \in \mathcal{Y}} \mathbb{P}[X = x, Y = y] \ell_{0-1}(y, f(x)) = \\
 & \mathbb{P}[X = x] (\mathbb{P}[Y = 0 | X = x] \Delta(0, f(x)) + \mathbb{P}[Y = 1 | X = x] \Delta(1, f(x)))
 \end{aligned}$$

אנו רוצים למזער את תוחלת השגיאה ככל הניתן ע"י קביעת  $h(x)$ .

אם  $h(x) = 1$ , נקבל כי השגיאה שתתרם היא

$$\mathbb{P}[Y = 0 | X = x] \Delta(0, f(x)) = \mathbb{P}[Y = 0 | X = x] a$$

אם  $h(x) = 0$ , נקבל כי השגיאה שתתרם היא

$$\mathbb{P}[Y = 1 | X = x] \Delta(1, f(x)) = \mathbb{P}[Y = 1 | X = x] b$$

לכן אם  $h(x) \in \operatorname{argmax}_{y \in \{0, 1\}} \{\mathbb{P}[Y = 0 | X = x] a, \mathbb{P}[Y = 1 | X = x] b\}$  נקבל כי תוחלת השגיאה תהיה מזערית.

2.

b.

נחשב כלל בחירה:

כפי שראינו בתרגול, מתקיים כי

$$\begin{aligned}\mathbb{P}[Y = 1|X = x] &> \mathbb{P}[Y = 0|X = x] \Leftrightarrow \\ \mathbb{P}[Y = 1]f_{X|Y}(x|1) &> \mathbb{P}[Y = 0]f_{X|Y}(x|0)\end{aligned}$$

מהנתון  $X|Y = 1 \sim \mathcal{N}(\mu_1, \Sigma)$ ,  $X|Y = 0 \sim \mathcal{N}(\mu_0, \Sigma)$

נציב ונקבל כי

$$\begin{aligned}\mathbb{P}[Y = 1|X = x] &> \mathbb{P}[Y = 0|X = x] \\ \Leftrightarrow \frac{e^{-\frac{1}{2}(x-\mu_1)^T \Sigma^{-1}(x-\mu_1)}}{(2\pi)^{\frac{d}{2}}|\Sigma|^{\frac{1}{2}}} p &> \frac{e^{-\frac{1}{2}(x-\mu_0)^T \Sigma^{-1}(x-\mu_0)}}{(2\pi)^{\frac{d}{2}}|\Sigma|^{\frac{1}{2}}} (1-p) \\ \Leftrightarrow \frac{(x-\mu_0)^T \Sigma^{-1}(x-\mu_0) - (x-\mu_1)^T \Sigma^{-1}(x-\mu_1)}{2} &> \log\left(\frac{1-p}{p}\right) \\ \Leftrightarrow \mu_0^T \Sigma^{-1} \mu_0 - 2\mu_0^T \Sigma^{-1} x + 2\mu_1^T \Sigma^{-1} x - \mu_1^T \Sigma^{-1} \mu_1 &> 2 \log\left(\frac{1-p}{p}\right) \\ \Leftrightarrow 2(\mu_1 - \mu_0)^T \Sigma^{-1} x &> 2 \log\left(\frac{1-p}{p}\right) + \mu_1^T \Sigma^{-1} \mu_1 - \mu_0^T \Sigma^{-1} \mu_0 \\ \Leftrightarrow 2 \sum_{i=1}^d (\mu_{1i} - \mu_{0i}) \sigma_i^{-2} x_i &> 2 \log\left(\frac{1-p}{p}\right) + \sum_{i=1}^d \sigma_i^{-2} (\mu_{1i}^2 - \mu_{0i}^2)\end{aligned}$$

ואפשר לראות כי במקרה ש- $d = 1$  נקבל את מה שראינו בתרגול.

c. עבור  $d = 1$  נקבל כי ה-*Decision boundary* הוא נקודה במישור חד מימדי  
עבור  $d = 2$  נקבל כי ה-*Decision boundary* הוא קו ישר במישור דו מימדי  
עבור  $d$  כלשהו נקבל מישור מישור  $d - 1$  מימדי.

d.

בלי הגבלת הכלליות נניח כי  $\sigma_1 > \sigma_0$

$$\begin{aligned}\mathbb{P}[Y = 1|X = x] &> \mathbb{P}[Y = 0|X = x] \\ \Leftrightarrow \mathbb{P}[Y = 1]f_{X|Y}(x|1) &> \mathbb{P}[Y = 0]f_{X|Y}(x|0) \\ \Leftrightarrow \frac{e^{-\frac{(x-\mu)^2}{2\sigma_1^2}}}{(2\pi)^{\frac{1}{2}}\sigma_1} p &> \frac{e^{-\frac{(x-\mu)^2}{2\sigma_0^2}}}{(2\pi)^{\frac{1}{2}}\sigma_0} (1-p)\end{aligned}$$

$$\begin{aligned}
&\Leftrightarrow \frac{(x-\mu)^2}{2\sigma_0^2} - \frac{(x-\mu)^2}{2\sigma_1^2} > \log\left(\frac{(1-p)\sigma_1}{p\sigma_0}\right) \\
&\Leftrightarrow (x-\mu)^2 \left(\frac{1}{2\sigma_0^2} - \frac{1}{2\sigma_1^2}\right) > \log\left(\frac{(1-p)\sigma_1}{p\sigma_0}\right) \\
&\Leftrightarrow (x-\mu)^2 > \log\left(\frac{(1-p)\sigma_1}{p\sigma_0}\right) \frac{2\sigma_1^2\sigma_0^2}{\sigma_1^2 - \sigma_0^2} \\
&\Leftrightarrow (x-\mu)^2 > \log\left(\frac{(1-p)\sigma_1}{p\sigma_0}\right) \frac{2\sigma_1^2\sigma_0^2}{(\sigma_1 + \sigma_0)(\sigma_1 - \sigma_0)} \\
&\Leftrightarrow x > \sqrt{\log\left(\frac{(1-p)\sigma_1}{p\sigma_0}\right) \frac{2\sigma_1^2\sigma_0^2}{(\sigma_1 + \sigma_0)(\sigma_1 - \sigma_0)}} + \mu \textbf{ or} \\
&x < -\sqrt{\log\left(\frac{(1-p)\sigma_1}{p\sigma_0}\right) \frac{2\sigma_1^2\sigma_0^2}{(\sigma_1 + \sigma_0)(\sigma_1 - \sigma_0)}} + \mu
\end{aligned}$$




## Programming Assignment

b. אחוז הדיוק של האלגוריתם אותו מימשתי עבור 1000 דגימות כפי שהוגדר בתרגיל עמד על 85.8% (עבור  $k = 10$ ).

עבור אלגוריתם שמקצה באופן רנדומלי הייתי מצפה לאחוז דיוק של 10%, מכיוון שגודל קבוצת התיוגים ( $Y$ ) הוא 10.

c. ניתן לראות כי ככל ש- $k$  גדל, כך הדיוק של  $k$ -NN יורד. ערכי ה- $k$  עבורם אחוז הדיוק היה הטוב ביותר הם  $k = 1, 2, 3, 4$  כאשר אחוז הדיוק עמד על כ-88%.

כאשר ערך  $k$  גדול, האלגוריתם חשוף הרבה יותר ל"רעש" שיש בדגימות, לכן האפקטיביות שלו יורדת.



- d. ניתן לראות כי אחוז הדיוק של האלגוריתם עולה משמעותית ככל שכמות דגימות האימון עולה.
- לדעתי, ניתן לייחס את השיפור הזה לשני גורמים עיקריים:
1. ערך ה-k: בסעיף הקודם ראינו כי עבור ערכי k קטנים יעילות האלגוריתם טובה יותר בדרך כלל
  2. איכות המדגם: ככל שכמות דגימות האימון עלתה, כך הן ייצגו את המציאות בצורה טובה יותר

